

Checklist da entrega vs. desafio AdzHub

Revisão do que o desafio pede (guia + página oficial) contra o que está entregue.

Paper (peso 50%, obrigatório)

Requisito	Status
PDF, máx. 3 MB, português	✓ 318 KB
Curto, estilo arXiv/OpenHands, porém simples	✓ 4 páginas, 2 colunas
Tese defendida (não só descrita)	✓ Harness Tri-Camada, justificada contra as 5
Anotações de estudo / decisões / trade-offs	✓ §1, §3.1, §3.3
Considera supercérebro + Apps + APIs	✓ §2.2 e §3.2 (o que é tool/memória/app)
Pontos críticos por tarefa do gestor	✓ §6 (relatório, diagnóstico, pauta, criativos)
As 11 perguntas do roteiro	✓ mapa em <code>paper/GUIA-D0-PAPER.md</code>
Figura + tabela + referências	✓ Figura 1, Tabela 1, 6 refs
Fontes de estudo registradas	✓ OpenHands, ReAct, CodeAct, RLM (2512.24601) , Zep/Graphiti, Anthropic

Protótipo (peso 25%, recomendado)

Requisito	Status
Chat web estilo Cursor que ilustra a tese	✓
Trace visível do harness (intent → tools → resposta)	✓ hidratação (fase) + tools por camada + resposta
OpenRouter como motor de LLM	✓ <code>web/js/openrouter.js</code>
Campo na UI para colar <code>OPENROUTER_API_KEY</code>	✓ modal Configurar
Key só na sessão do browser, não persiste no servidor	✓ <code>sessionStorage</code> , nunca vai ao backend
Trocar de modelo	✓ dropdown clicável
Simula tools/APIs/Supercérebro com dataset	✓ 7 mocks cruzados (Housewhey)
Deploy público (Railway recomendado)	✓ https://adzhub-harness-production.up.railway.app
UI/UX	✓ tema claro/escuro, tabelas estilo Ads Manager, resposta digitada ao vivo, animações, trace agrupado (Nx)
Persona própria (não é chatbot genérico)	✓ NEXO , estrategista de performance, em <code>web/js/nexo.js</code> (fora do runtime)
Consumo de tokens visível pro gestor	✓ por chamada (trace), por turno (rodapé com tabela) e por sessão (medidor no topo), com custo em US\$ quando o provedor devolve
Bônus: roda sem key (modo simulado)	✓ avaliador testa sem colar chave

Formulário

Campo	Valor
Nome completo	Rafael Yran Azevedo
WhatsApp	o mesmo da candidatura
Tipo de harness	Outra / híbrida / própria (Harness Tri-Camada)
Paper (PDF)	<code>paper/paper.pdf</code>
Repositório GitHub (público)	<code>https://github.com/haestare/adzhub-harness</code>
URL da demo	<code>https://adzhub-harness-production.up.railway.app</code>
Notas	só-leitura por design, dados mock, 5 problemas plantados não rotulados, modo simulado + LLM/OpenRouter

Estado do protótipo (o que o avaliador encontra)

Recurso	Situação
Persona própria (NEXO), fora do runtime	✓ <code>web/js/nexo.js</code>
Trace do harness com badge por camada e agrupamento <code>N×</code>	✓
Medidor de tokens (por chamada, por turno, por sessão)	✓ medido no LLM, estimado com $\approx$ no simulado
Streaming SSE real, com <code>tool_calls</code> remontados	✓
Tabelas estilo Ads Manager + títulos h1-h3	✓ <code>build/test_md.js</code> trava a regressão
Tema claro/escuro persistente	✓
Comandos de barra (10, com paleta)	✓ <code>/tools</code> e <code>/uso</code> deixam o harness inspecionável
Dropdown de modelos ranqueado (#1 = mais forte), lista viva da API	✓ fallback local sem rede
Deploy automático a cada commit	✓ <code>.githooks/post-commit</code> + hook <code>Stop</code>

Melhorias já aplicadas nesta revisão

- Paper: citação do RLM (arXiv:2512.24601) e nod ao GraphRAG, que a página lista.
- Protótipo: o agente agora é instruído a usar **tabela** para dados comparativos (não lista aninhada).
- Protótipo: **tema claro/escuro** com toggle (persistente, sem flash ao abrir).
- Protótipo: dropdown de modelo, tabelas estilo Ads Manager, trace agrupado (`N×`).
- Protótipo: **streaming SSE real** no modo LLM. O texto aparece token a token enquanto o modelo gera; os `tool_calls` chegam fatiados e são remontados no transporte, então o loop inteiro é streamado sem chamada extra. No modo simulado continua o typewriter (não há LLM para streamar).
- Protótipo: **persona NEXO**. O agente deixou de ser "assistente" e virou estrategista: conclusão primeiro, fato separado de hipótese e de recomendação, opinião amarrada ao número, e discrepância entre Meta e CRM exposta em vez de resolvida em silêncio. A persona vive em `web/js/nexo.js`, separada do runtime, e o modo simulado segue a mesma régua (senão trocar de motor trocaria de agente).

- Protótipo: **medidor de tokens**, por chamada, por turno e por sessão, com custo em US\$ quando o provedor devolve.
 O `usage` do streaming chega num chunk com `choices: []`, então o transporte captura antes de descartar o chunk por falta de delta; sem isso o número sumiria sem erro nenhum. `build/test_uso.js` cobre isso e mais 19 asserções, sem rede e sem chave.
- Docs: `paper/GUIA-D0-PAPER.pdf` e `CHECKLIST.pdf` (versões em PDF, mais fáceis de ler).

Opcionais que ficam de fora (não bloqueiam a entrega)

- Ouvir o **podcast AdzHub · Harness** e o **How I AI** e citar uma frase no §1 (reforça o critério "aprofundamento no estudo"). Deixei de fora do paper para não afirmar o que você ainda não ouviu.
- Um segundo cliente no mock, para mostrar multi-conta (o paper já assume um cliente por escolha de MVP).