

Harness Tri-Camada: memória como ambiente, API como tool, App como skill

Um runtime híbrido (ReAct + contexto-ambiente + skills) para o chat agêntico de marketing da AdzHub

Rafael Yran Azevedo

Candidato · Desafio Harness Agêntico · AdzHub Núcleo Fundacional, 2026

RESUMO. O gestor de marketing da AdzHub não precisa de um chatbot que responde: precisa de um agente que resolve tarefas compostas (cruzar gasto de anúncio com venda real, diagnosticar um CPA que subiu, montar a pauta de uma call) navegando o histórico da conta. Defendo que o erro comum, tratar tudo como *tool*, subutiliza o domínio. Proponho um harness híbrido de três mecanismos, um por camada: a memória (supercérebro: grafo + linha do tempo) é **hidratada como ambiente** antes do loop, não consultada às cegas; as APIs (Meta, CRM) são **tools** num loop ReAct; e os Apps de metodologia são **skills** encapsuladas que o harness invoca sem reimplementar. Um protótipo web de chat ilustra a tese sobre um dataset mock da Housewhey, com o *trace* do harness visível (hidratação → tools → observações → resposta) e cinco problemas de gestão plantados e não rotulados. Do protótipo sai também uma medição que muda decisão de projeto: num turno de cinco passos a entrada cresce de 2,9k para 11,3k tokens contra ~434 de saída, ou seja o custo de um harness ReAct é dominado pelo reenvio de observação, não pela geração. O que fica só no paper: a construção do grafo temporal real, permissões de escrita e avaliação automática. O recorte consciente: nenhuma ação que escreve na conta; o MVP lê, diagnostica e propõe.

Palavras-chave: harness agêntico, ReAct híbrido, memória temporal, contexto como ambiente (RLM), skills, orquestração, marketing.

1. Introdução

O produto-alvo é um chat agêntico (no espírito do Cursor, mas para marketing): o gestor descreve uma tarefa e o agente orquestra contexto, Apps e APIs até uma ação útil. Antes de desenhar, separo dois conceitos que se confundem. O **modelo** é o LLM: prevê o próximo token e, no máximo, emite a intenção de chamar uma função. O **harness** é o runtime em volta: o loop que executa a chamada, injeta a observação de volta, guarda estado, impõe limites (allowlist de tools, teto de passos) e decide o que entra no contexto. Trocar de modelo troca o raciocínio; trocar de harness troca o que o agente consegue fazer com aquele raciocínio.

Uma imagem fixa a distinção. O LLM é um cérebro num pote: sabe muito, mas não vê o mundo nem age. O harness é o exoesqueleto que pluga esse cérebro na operação. O exoesqueleto restringe o foco (em vez de deixar o cérebro divagar, prende ele nos passos daquela tarefa), provê os músculos e as ferramentas (tools, memória, dados da conta) e força a saída num comportamento estrito. E faz isso *sem tocar no cérebro*: não mexemos nos pesos do modelo (isso seria treino), apenas embrulhamos software em volta e filtramos o que o LLM vê. Mesmo cérebro, exoesqueletos diferentes, agentes diferentes.

No início do estudo eu tratava harness como sinônimo de "loop de tool-calling": ligar o modelo a um punhado de funções e deixar rodar. Estudando os tipos de referência (ReAct [2], sandbox/CodeAct [3], sessão com permissões e skills, orquestração por grafo, contexto como ambiente [4]) e o SDK do OpenHands [1], o que mudou foi entender que a decisão de arquitetura não é "qual loop", e sim **como cada recurso do**

domínio entra no runtime: o que vira tool, o que vira memória e o que vira unidade de trabalho encapsulada. Um bom harness é, antes de tudo, uma política de contexto.

Tese. Para este domínio, um harness que trata suas três camadas com o mesmo mecanismo (tudo tool) é caro e frágil; defendo um híbrido em que *memória é ambiente, API é tool e App é skill*. As seções §2 a §7 definem o vocabulário, justificam a escolha contra as alternativas, mostram o que o protótipo ilustra e onde a solução quebra.

2. Preliminares

2.1. As peças do exoesqueleto

Retomo a imagem da introdução, porque ela dá nome a cada peça sem jargão. Um harness é o exoesqueleto que veste o cérebro, e tem seis partes. Descrevo cada uma pelo que ela faz no trabalho do gestor, não pelo termo técnico.

- **O ciclo de passos (loop).** O agente não responde de um fôlego só: ele dá voltas. É o mesmo movimento do gestor que abre o Gerenciador, vê que o CPA subiu, e só então decide abrir o CRM. Cada volta usa o que a anterior trouxe, e é isso que separa investigar de chutar.
- **As mãos (tools).** São as funções que o cérebro pode pedir para acionar: puxar os anúncios do Meta, os leads do CRM. O modelo não executa nada; ele pede, e o exoesqueleto executa.
- **O tato (observação).** O que a mão traz de volta. Sem isso o agente seria cego: é a observação que o faz mudar de ideia no meio do caminho, quando o CRM mostra duas vendas onde o Meta prometia quatorze.

- **A memória.** O que ele já sabe antes de perguntar: quem é o cliente, quais campanhas existem, o que foi decidido na última call. Sem memória, toda pergunta começa do zero.
- **As travas (*allowlist* e *teto de passos*).** A lista fechada do que ele pode acionar e quantas voltas pode dar. É o que impede o exoesqueleto de sair andando sozinho, e o que separa um agente de um chatbot solto.
- **O que sobrevive entre as voltas (*estado*).** As mensagens, os resultados já obtidos, as decisões tomadas. Sem estado, a segunda volta esquece o que a primeira descobriu.

Nenhuma dessas peças está no modelo: todas são do runtime em volta dele. É por isso que dois produtos com o mesmo LLM entregam agentes diferentes.

2.2. O domínio AdzHub (como eu o leio)

A página do desafio expõe três camadas. **(i) Supercérebro:** a memória da operação, pessoas, cliente, campanhas e decisões ligadas em grafo (GraphRAG), com linha do tempo (contexto temporal). **(ii) Apps:** metodologias empacotadas (insight da semana, brief de criativo, diagnóstico, análise de criativos, mapa de solução). **(iii) APIs:** os dados da operação (Meta, Google, Analytics, CRM, WhatsApp). A observação central deste paper: essas três camadas têm *naturezas* diferentes, e o harness rende mais quando respeita essa diferença em vez de achatar tudo em "função que o LLM chama".

Por que o supercérebro é um grafo, e não uma tabela. O que o gestor precisa saber quase nunca está num registro só: está na *ligação* entre registros. "Por que o criativo de Creatina não subiu" se responde ligando criativo → tarefa de aprovação → pessoa que aprova → decisão registrada na call → restrição do mapa de solução. Numa tabela isso é um *join* que alguém precisa ter previsto; num grafo é caminhar de vizinho em vizinho, e é por isso que a recuperação pode partir de um nó qualquer citado na pergunta. As entidades que valem a pena existem como nó são poucas e estáveis: cliente, campanha, criativo, pessoa, decisão, tarefa, restrição de marca. As arestas carregam o que a tabela perde: quem decidiu, para quem, a partir de qual conversa.

Por que a linha do tempo é uma camada e não um campo de data. Nenhuma afirmação de performance significa algo fora de uma linha de base: "o CPA subiu" só existe contra o CPA de antes. E, mais importante, fato de operação *vence*: "o cliente não quer falar em resultado garantido" era verdade em março e continua; "a verba é de R\$ 5.000" pode ter mudado na semana passada. Uma memória que só acumula texto responde com o fato revogado e soa confiante. Por isso trato tempo como parte da memória (o que valia quando), no espírito do grafo temporal com invalidação [5], e não como uma coluna `created_at` que ninguém consulta.

Por que um App não é só mais uma tool. As duas são "função que o harness chama", e é aí que a distinção parece

pedante. A diferença é o que cada uma carrega: a tool carrega *dado* (o gasto do anúncio é o que é), e o App carrega *opinião do negócio* (o que conta como criativo saturado, quando recomendar pausar, o que a marca não pode falar). Colocar metodologia no prompt tem três custos que a versão encapsulada não paga: ela é reprocessada pelo LLM a cada turno (token), pode ser reinterpretada de um jeito diferente a cada turno (consistência), e deixa de ser versionável pelo time que a escreveu (produto). Um App é a metodologia da AdzHub virando código chamável; se ela vira parágrafo de prompt, ela vira sugestão.

O que os canais mudam. WhatsApp e reuniões não são mais uma fonte de métrica, são onde mora o *porquê*: a aprovação que travou, o combinado da call, a reclamação que antecede o pedido de relatório. É a única camada que explica decisão humana, e é por isso que ela entra como memória e não como API de dado. Já Analytics ao lado de Meta e CRM cria um problema que o harness precisa assumir em vez de esconder: **três sistemas contam a mesma venda de três jeitos** (janelas de atribuição e modelos diferentes). O desenho aqui não elege um vencedor em silêncio; expõe a divergência, que é exatamente o quinto problema plantado no dataset (§4.2).

2.3. Cinco famílias de harness (o terreno estudado)

Antes de escolher, mapeei as famílias que aparecem na literatura e nos produtos. Resumo o que cada uma propõe de fato, não o rótulo, porque a diferença entre elas não é de estilo: é de *onde* o trabalho acontece.

ReAct [2] intercala raciocínio e ação no mesmo traço: o modelo escreve o que pensa, escolhe a ação, lê a observação e revisa o pensamento. O ganho não é a chamada de função em si (qualquer loop faz isso), é a observação poder *corrigir* o raciocínio no meio do caminho. **CodeAct** [3] muda o espaço de ação: em vez de JSON, o agente escreve código executável, o que dá laço, condicional e reaproveitamento de resultado anterior de graça, ao custo de um sandbox. O **SDK do OpenHands** [1] mostra o harness como produto de engenharia: fluxo de eventos como estado, runtime isolado, tools plugáveis e uma camada que inspeciona a ação antes de executar. **RLM** [4] muda a pergunta: em vez de empurrar tudo para dentro do prompt, trata o contexto como um ambiente que o modelo percorre. A nota da Anthropic [6] separa *workflow* (caminho predefinido em código) de *agente* (o modelo dirige o próprio processo) e recomenda a coisa mais simples que resolve, o que é um argumento direto contra orquestrar este chat por grafo de estados. E a memória por grafo temporal [5] fecha o mapa pelo lado do dado: fatos com validade, que mudam e são invalidados no tempo.

A Tabela 1 põe as cinco lado a lado com o veredito que cada uma recebeu neste desenho. A coluna que decide não é "onde brilha", é **onde falha no chat do gestor**: é ela que explica por que a resposta não é escolher uma, e sim compor.

Tabela 1. As cinco famílias estudadas e o veredito de cada uma para o chat agêntico de marketing.

Família	Onde o trabalho acontece	Brilha quando	Onde falha no chat do gestor	Veredito aqui
ReAct [2]	loop pensa → age → observa	a tarefa é aberta e exige investigar	sozinho, memória vira "mais uma tool" e o modelo precisa lembrar de buscar contexto	adotado como núcleo
CodeAct / sandbox [3]	código executado em ambiente isolado	cálculo encadeado, engenharia, transformação de dado	soma execução e latência para um trabalho que é cruzar tabela e aplicar método	fora do MVP; volta como tool de verificação (§7)
Sessão com permissões e skills [1]	unidade de trabalho encapsulada + porteiro antes da ação	metodologia repetível e ação que escreve	permissão resolve um risco que o MVP não corre, porque ele é só-leitura	metade: skills sim, permissões adiadas
Orquestração por grafo de estados	caminho desenhado antes de rodar	o fluxo é conhecido e se repete igual	é uma tarefa diferente por mensagem; caminho fixo engessa e falha no caso novo [6]	fora (o grafo aqui é de dados, não de controle)
Contexto como ambiente (RLM) [4]	recuperação antes do loop	todo pedido pressupõe histórico da conta	sozinho não age: não chama API nem executa metodologia	adotado para a camada de memória

3. Arquitetura

3.1. A escolha: um híbrido de três mecanismos

A Tabela 1 já traz o veredito de cada família. O que explico aqui é a *composição*, porque é nela que está a tese: a decisão não é "qual das cinco", é **qual mecanismo para qual camada**. Nenhuma delas cobre as três sozinha.

Núcleo ReAct, porque a tarefa é aberta. O gestor não manda um comando por vez, ele descreve um problema ("o CPA subiu, o que houve"), e o caminho até a resposta só se descobre andando: o número do Meta é que faz querer abrir o CRM. Isso é exatamente o que o loop pensa-age-observa entrega, e é o motivo de eu não usar um grafo de controle: caminho desenhado antes só funciona quando o fluxo se repete, e aqui cada mensagem é uma tarefa diferente [6].

Memória fora do loop, porque toda pergunta pressupõe histórico. Esta é a correção que o ReAct puro precisa neste domínio. Se o supercérebro for só mais uma tool, o modelo tem que *lembrar* de consultá-lo, e erra dos dois lados: às vezes responde no vácuo, às vezes gasta dois passos buscando o que já devia estar na mão. Trato a memória como ambiente [4]: antes do loop, o harness recupera um pacote (nós relevantes do grafo + eventos recentes da timeline) e injeta no prompt. O agente já começa situado, e a memória continua disponível como tool para o aprofundamento sob demanda.

Apps como skills, porque metodologia é produto e não prompt. A parte de *skills* da referência de sessão eu adoto inteira: o App é chamado, devolve ranking e recomendação, e o harness usa a saída sem recriar o método. A parte de *permissões* eu adio de propósito, porque o MVP não escreve na conta (§3.3). Uso metade da referência, conscientemente, e digo qual metade.

O híbrido, então: **RLM para a memória, ReAct para as APIs, skills para os Apps**. A tese não está em nenhuma das

três escolhas isoladas, está na composição, e o que a justifica é a Tabela 1: cada família falha justamente na camada que outra cobre.

3.2. O que é tool, o que é memória, o que é app

Memória (supercérebro), hidratada como ambiente. Antes do loop, o harness chama uma recuperação (`search_client_context + get_timeline`) semeada pela intenção e injeta um pacote compacto no *system prompt*. Durante o loop, o modelo ainda pode aprofundar (buscar uma ata com `search_conversations`). Memória é ambiente por padrão, tool sob demanda.

API (Meta, CRM), tools clássicas. Sem estado, chamadas dentro do loop: `list_ads` e `get_ad_insights` (gasto, série semanal, saturação), `get_leads` (venda real). O join Meta×CRM por `utm_content = ad_id` é trabalho do *agente*, não da *tool*: é aí que mora a inteligência de "não confiar só no gerenciador".

App (metodologia), skills encapsuladas. `run_app_analise_criativos` devolve `ranking + recomendação` (seguir/pausar/variante); `get_mapa_solucao` devolve a ficha da marca (o que não pode falar). O harness chama o app e usa a saída; não recria a metodologia no prompt. Isso mantém a metodologia versionável no produto e barata em tokens.

3.3. Trade-offs aceitos de propósito

- **Fidelidade vs simplicidade:** a hidratação é uma recuperação simples (match no grafo + últimos N eventos), não um recuperador semântico com embeddings. Aceito recall menor por latência baixa e previsibilidade; num MVP, contexto errado é pior que contexto raso.
- **Latência vs profundidade:** `max_steps = 8` e allowlist fechada. Prefiro cortar cedo e responder com o que há a divagar.

- **Custo:** Apps como skills e `get_leads` com sumário cortam tokens; a metodologia não é reprocessada pelo LLM a cada turno.
- **Segurança:** só-leitura. Nenhuma tool escreve na conta (não pausa anúncio, não mexe em verba). O agente propõe; o humano executa. Remove a classe inteira de risco de ação indevida e é coerente com "o gestor decide".
- **Simplicidade do MVP:** um cliente, tools que leem mocks. Sem multi-tenant, sem auth, sem escrita.

4. Sistema

4.1. O que o protótipo ilustra

Um chat web (estilo Cursor) roda o harness sobre um dataset mock da Housewhey, com um agente de persona própria (NEXO, estrategista de performance). A persona vive num arquivo separado do *runtime*, de propósito: o loop é mecanismo, a persona é dado do harness, e o mesmo runtime serve outra persona sem alteração de código. Cada turno mostra, num painel de *trace*, as fases do harness: hidratação do supercérebro (fase), depois as tool calls (com *badge* por camada: memória/api/app), com args e observação inspecionáveis, e a resposta ancorada nos números. Dois motores compartilham o mesmo trace: **(a) Simulado**, sem chave, um planejador roteirizado que executa as tools reais e

compõe a resposta a partir do dado (prova que o dado sustenta a conclusão); **(b) LLM**, via OpenRouter, o loop ReAct de verdade decide as chamadas.

Um turno concreto (intent → memória/tools → observação → resposta), para "o CPA do Ômega 3 subiu, diagnostique":

- **Hidratação:** nós do grafo (campanha Ômega 3, time, tarefa de aprovação) + timeline recente entram no prompt.
- **Loop:** `list_ads` (gasto por anúncio) → `get_leads` (venda real) → `get_ad_insights` (hook_rate 32%→18%, frequência 1,8→4,8) → `run_app_analise_criativos` (recomenda pausar).
- **Observações combinadas:** o criativo de depoimento tem CPA R\$ 2.100 contra R\$ 100 do antes/depois, saturou e sozinho estourou o orçamento (R\$ 6.200 vs R\$ 5.000).
- **Resposta:** causa raiz + próximo passo: pausar o depoimento resolve CPA, fadiga e verba de uma vez.

Observabilidade inclui custo, e o custo tem um formato surpreendente. Um turno de agente não é uma chamada de LLM, são N: uma por passo do loop, e *cada passo reenvia a conversa inteira mais todas as observações já colhidas*. Isso é estrutural em qualquer harness ReAct, e é invisível para quem só olha o preço por token. O protótipo mostra o consumo por chamada, por turno e por sessão, e o Quadro 1 traz o turno de diagnóstico acima medido passo a passo.

QUADRO 1. Custo real de um turno de 5 passos (diagnóstico do Ômega 3). A entrada cresce quase 4x ao longo do turno; a saída do turno inteiro cabe em ~434 tokens.

Passo	O que o modelo decidiu ali	Entrada (tokens)	Por que cresceu
1	chamar <code>list_ads</code>	2.900	prompt + memória hidratada
2	chamar <code>get_leads</code>	3.800	+ observação do passo 1
3	chamar <code>get_ad_insights</code>	10.400	+ leads (a observação mais pesada)
4	chamar <code>run_app_analise_criativos</code>	10.700	+ série semanal
5	escrever a resposta	11.300	+ recomendação do App

A leitura: o custo de um harness ReAct é dominado pelo *reenvio* de observação, não pela geração. Uma tool que devolve JSON cru não custa uma vez, custa uma vez por passo restante do turno. É esse número, e não o gosto do desenvolvedor, que decide se `get_leads` devolve a lista inteira ou um sumário. (Valores da estimativa do modo simulado, que reconstrói o loop passo a passo; no modo LLM o mesmo painel mostra o *usage* medido pela API, e medido nunca aparece sem rótulo ao lado de estimado.)

4.2. Datasets: o que é fake, o que dá para testar

Sete arquivos JSON (um cliente, cruzados: `ad_id` = `utm_content`, pessoas no grafo, timeline e WhatsApp). Cada arquivo é uma tool (Tabela 2). Tudo é fake, mas coerente ponta a ponta; **cinco problemas de gestão estão plantados e não**

rotulados: CPA estourado, criativo saturado, origem declarada que mente contra o UTM, aprovação travada por *claim* proibido, e spend vs budget. O avaliador cola três prompts (relatório, diagnóstico, origem dos leads) e vê o harness orquestrar duas ou mais tools e chegar à conclusão sem que ela esteja escrita no dado.

Tabela 2. Peças do harness: o que é cada uma e onde vive.

Peça (tool)	Camada	Papel na tese	Estado no protótipo
<code>search_client_context</code>	Supercérebro · grafo	Memória (ambiente): quem/o quê da conta	simulado sobre mock; visível no trace
<code>get_timeline</code>	Supercérebro · temporal	Memória (ambiente): histórico recente	simulado sobre mock; visível no trace

search_conversations	Memória de canal	Memória (sob demanda): o porquê (aprovação)	simulado sobre mock; visível no trace
list_ads / get_ad_insights	API · Meta Ads	Tool: gasto, série, saturação	simulado sobre mock; visível no trace
get_leads	API · CRM	Tool: venda real, atribuição	simulado sobre mock; visível no trace
run_app_analise_criativos	App · metodologia	Skill: ranking + recomendação	simulado sobre mock; visível no trace
get_mapa_solucao	App · marca	Skill: restrições ("não pode falar")	simulado sobre mock; visível no trace

4.3. OpenRouter e troca de modelo

No painel **Configurar**, o avaliador escolhe o motor (Simulado ou LLM) e cola a `OPENROUTER_API_KEY`, guardada só em `sessionStorage` e enviada apenas à OpenRouter, nunca a um servidor nosso. O modelo sai de um dropdown montado a partir da API pública da OpenRouter, buscada pelo browser do avaliador e filtrada por quem suporta *tool-calling* (sem isso o harness não existe: o modelo responderia texto sem nunca tocar numa tool). A lista vem em **três grupos**, porque duas perguntas diferentes precisam de resposta: *recomendados*, ranqueados do mais forte (#1) ao mais fraco e com um por família, responde "qual eu uso"; *grátis* reúne os de custo zero, para avaliar sem gastar; e o **catálogo inteiro**, em ordem alfabética, responde "quero este aqui". Uma quarta opção aceita um id digitado, para o modelo que nasceu depois desta lista. A lista é uma *listbox* própria, com filtro por id: o `<select>` nativo abre sempre rolado até o item escolhido, o que com centenas de modelos jogava os recomendados para fora da tela, e essa rolagem não é configurável. Fixar ids à mão envelhece e vira 400 na hora da avaliação; o ranking é heurística declarada (família, preço de saída, contexto) casada por padrão de nome, e sem rede cai numa lista local, que não anuncia nada como grátis porque preço ausente não é preço zero. O modo Simulado dispensa chave e serve quem só quer ver o harness orquestrar.

5. Notas de execução

PDF anexo (este). Demo opcional: chat web estático, roda de `file://` por duplo clique ou de qualquer host, sem backend. LLM via OpenRouter, chave só na sessão do browser. Dados mock gerados de forma determinística a partir do `dataset_prompt`. Consumo de tokens medido pelo `usage` da própria API no modo LLM e estimado (sempre marcado com $\approx$) no simulado, onde não há LLM para medir. A resposta é streamada (SSE), com duas notas de engenharia que só aparecem ao streamar um loop *com tools*: os `tool_calls` chegam **fatiados** (nome e argumentos em pedaços indexados) e precisam ser remontados no transporte, senão o nome da tool chega quebrado; e o texto escrito *antes* de uma tool é raciocínio, não resposta, então migra para o trace em vez de ficar colado na resposta final. Comandos de sessão (`/tools`, `/uso`) rodam localmente, fora do harness. O que é fake: todas as métricas e nomes. O que "parece real": o cruzamento e o trace, porque as tools leem o mesmo dado que a resposta cita, e o avaliador pode abrir cada passo.

6. Pontos críticos por tarefa do gestor

Uma arquitetura só se avalia contra o trabalho real. Percorro as tarefas do dia a dia do gestor da AdzHub (as que os Apps cobrem, mais as duas que atravessam tudo, relatório e call) e digo, em cada uma, onde *este* desenho ajuda e onde ele quebra. A Tabela 3 é o resumo; os dois casos mais graves ganham parágrafo depois.

Tabela 3. Onde o Harness Tri-Camada ajuda e onde ele quebra, por tarefa do gestor.

Tarefa	O que o harness faz	Ponto crítico	O que no desenho mitiga (e o que não)
Insight da semana (relatório)	cruza gasto do Meta com venda do CRM por <code>utm_content</code> e ordena por custo por venda	o cruzamento vale o que vale o UTM; atribuição divergente entre Meta e CRM muda o ranking	expõe a divergência em vez de escolher um lado; não reconcilia janelas de atribuição
Diagnóstico (o CPA subiu)	hidrata a campanha, puxa série e frequência, chama o App de criativos	o agente correlaciona, não prova causa; hidratação rasa pode não trazer o nó certo	separa fato de hipótese na resposta; não faz teste estatístico
Análise de criativos	invoca o App e usa ranking + recomendação (seguir/pausar/variá)	o App julga pelo número, sem ver a peça: criativo bom com oferta errada é indistinguível	metodologia versionada fora do prompt; não analisa imagem nem vídeo
Brief de criativo	gera o brief a partir do que venceu, com o mapa de solução no contexto	é a única tarefa <i>geradora</i> : o LLM pode propor copy que a marca não pode falar	injeta <code>get_mapa_solucao</code> ; não garante, porque restrição no prompt é instrução, não trava

Mapa de solução (restrições)	lê a ficha da marca como skill e a usa como limite do que sugerir	a ficha é um retrato: cliente muda de posicionamento e ninguém reescreve o documento	tempo é camada de memória (fato vence); não detecta sozinho que a ficha envelheceu
Pauta de call	lê timeline e conversas, monta o que mudou e o que ficou pendente	o harness não sabe o que não foi registrado: memória esparsa vira pauta genérica	puxa o canal (WhatsApp) junto; não inventa o que ninguém anotou
Responder o cliente	recupera o histórico do canal e propõe a resposta	é onde uma ação errada custa relacionamento, não só verba	só-leitura por desenho: o agente redige, o humano envia; não automatiza o envio

O crítico do relatório é atribuição, não join. No mock, `utm_content = ad_id` sempre bate, e é isso que faz a demo parecer limpa. Na conta real, UTM falta, vem errado, e o mesmo lead toca três anúncios antes de comprar; Meta credita por visualização dentro da janela dele, o CRM credita o último clique, e os dois estão "certos" pelas próprias regras. Um agente que escolhe uma fonte e segue em frente produz um número que ninguém consegue auditar. Por isso o quinto problema plantado no dataset é exatamente esse (leads que declaram Google mas carregam UTM do Meta), e por isso a persona é instruída a *expor* a discrepância. Resolver de verdade é um projeto de atribuição, não um prompt.

O crítico do diagnóstico é confundir correlação com causa. "O criativo saturou" é a leitura mais provável quando frequência sobe e hook rate cai, mas continua sendo leitura: pode ser sazonalidade, concorrente novo no leilão, ou mudança na página de destino que o agente nem enxerga. O desenho responde a isso separando na saída o que é fato medido, o que é hipótese e o que é recomendação, o que devolve ao gestor a decisão de confiar. O que ele não faz é medir a confiança dessa hipótese, e isso não é detalhe: um agente que fala com a mesma segurança nos dois casos treina o gestor a parar de conferir.

7. Limitações e próximos passos

Além dos pontos críticos por tarefa: só-leitura por escolha (não fecho o loop de execução); um cliente só (sem multi-tenant nem auth); memória mock, sendo que o grafo temporal de verdade (resolução de entidade, invalidação, decaimento) é o trabalho pesado que fica de fora. O protótipo também não trata sessão longa: hoje o turno é curto, e o Quadro 1 mostra por que

isso não escala sozinho, mas a política de compactação de contexto ao longo de uma conversa de quarenta mensagens não está desenhada.

Com mais uma semana eu construiria: (a) recuperação de memória de verdade, um grafo temporal com embeddings e decaimento (no espírito de Graphiti/Zep [5]), para a hidratação parar de depender de match por substring; (b) uma tool isolada de verificação numérica, o único lugar onde um mini-sandbox se paga, para o join Meta×CRM ficar auditável; (c) confirmação de escrita (pausar anúncio) com o humano no meio. **O que eu deliberadamente não construiria:** um grafo de controle por cima do chat (mata a abertura da tarefa), execução de código arbitrário no MVP (risco sem retorno) e memória de longo prazo que aprende sozinha sem revisão, porque num domínio com o dinheiro do cliente, contexto errado propaga erro.

Referências

- OpenHands. *The OpenHands Software Agent SDK*. arXiv:2511.03690, 2026.
- S. Yao et al. *ReAct: Synergizing Reasoning and Acting in Language Models*. arXiv:2210.03629, 2023.
- X. Wang et al. *Executable Code Actions Elicit Better LLM Agents (CodeAct)*. arXiv:2402.01030, 2024.
- Recursive Language Models*. arXiv:2512.24601, 2026.
- P. Rasmussen et al. *Zep / Graphiti: memória de agente por grafo de conhecimento temporal*. 2025.
- Anthropic. *Building Effective Agents*. Nota de engenharia, 2024.

Documento do candidato para o Desafio Harness Agêntico da AdzHub.
Nomes de cliente, tools e métricas são ficção ilustrativa (mock Housewhey).